Tujya : rapport technique du module 2, AI Engineering

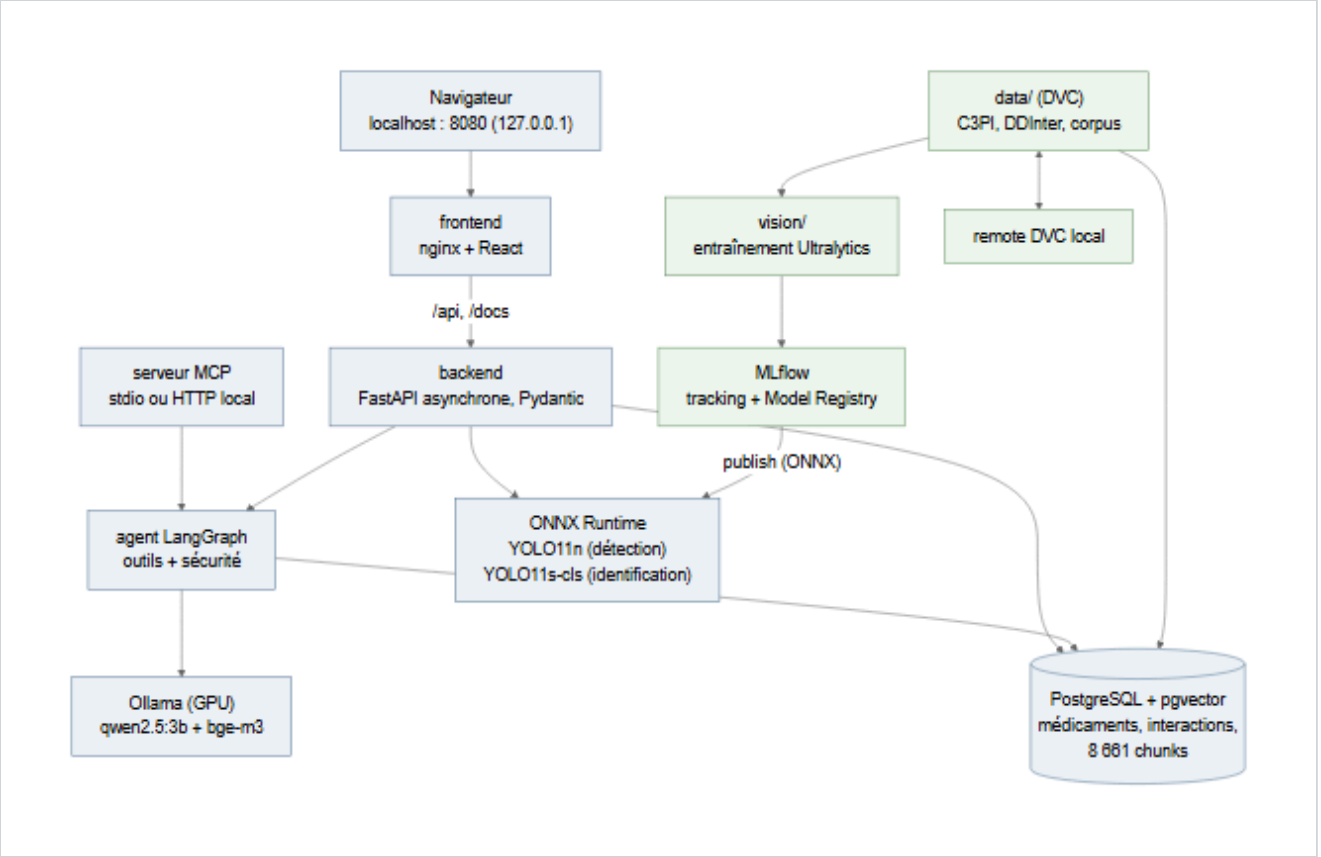
Projet étudiant solo. Dépôt : https://github.com/melekbouabid/tujia- (code, documentation et historique des commits ; données hors de git). Rapport rédigé le 2026-10-28 ; tous les chiffres viennent des documents du dépôt (docs/RAG.md, docs/AGENT.md, docs/MCP.md, docs/BENCHMARK.md) et des runs MLflow de l'expérience `tujya-rag` ; aucun n'est estimé.

> Tujya ne donne jamais de dose, ne dit jamais qu'une association est « sûre » (au mieux « aucune interaction connue dans cette base de données ») et cite toujours ses sources. Information uniquement, consultez un pharmacien ou un médecin.

1. Contexte

Le module 1 identifie des comprimés sur une photo et vérifie leurs interactions dans DDInter. Le module 2 permet de **poser des questions de suivi** (« Le fluconazole et le citalopram interagissent-ils ? », « Quelles sont les contre-indications de la metformine ? ») et d'obtenir une réponse **fondée uniquement sur des documents cités**, avec des règles de sécurité médicales appliquées dans le code.

Exigence du module 2	Réalisation	Section
RAG : gestion des documents, métadonnées, citations, documentation	corpus de 8 661 chunks, 18 colonnes de métadonnées, citations [n]	2, 3
Tool calling / MCP	4 outils appelés par le LLM (+ 1 en bonus) ; serveur MCP officiel	4, 5, 9
LangChain / LangGraph	graphe LangGraph à 5 nœuds, outils LangChain	4
Benchmark de la récupération et de la génération	88 questions, Recall@k / MRR, sécurité, citations, RAGAS	7
Interface web	panneau de chat sur la page Scanner	8
Dépôt documenté, commits réguliers	docs/, journal du README, historique git	—



Architecture : l'agent, Ollama et pgvector dans la même pile Docker Compose, sur ce PC.

2. Corpus et métadonnées

Le corpus porte sur les **82 principes actifs** des 150 classes de comprimés.

Type	Source	Licence	Documents	Chunks
`label`	notices openFDA (SPL)	CC0 / domaine public	82 (une par principe actif)	2 895
`abstract`	résumés PubMed (E-utilities)	conditions NLM	1 570	3 416
`interaction`	DDInter 2.0, paires entre les 82 principes actifs	CC BY-NC-SA 4.0	2 350	2 350
Total			**4 002**	**8 661**

- **Notices openFDA** : nouveau connecteur `openfda_label` dans le style du pipeline existant (client poli à 3 requêtes/s, cache HTTP, manifeste SHA-256, provenance). Une notice par principe actif selon une **règle fixe et auditable** (D60) : la notice concerne bien le principe actif, mono-principe actif avant association, sur ordonnance avant OTC, le plus de sections utiles, la plus récente. Résultat : 82/82 (81 sur ordonnance, 1 OTC), dates de 2021-09-30 à 2026-09-11. Les 25 candidates sont gardées avec la notice choisie.
- **PubMed** : mode `ingredients` du connecteur existant : interactions ou effets indésirables, résumés en anglais depuis 2000, tri par pertinence, **20 au plus par principe actif** (D61) : 1 570 articles distincts (17 à 20 par principe actif), dont **4 rétractés**, gardés avec `is_retracted = true` et exclus de la recherche par défaut.
- **DDInter** : une ligne par paire ; « Unknown » est écrit « interaction dont DDInter ne donne pas la sévérité », jamais « pas d'interaction ». Les 40 508 paires avec n'importe quel médicament restent

hors de l'index texte mais sont lues par l'outil `check_interaction` (D62).

- **Métadonnées** (une ligne par chunk, `chunks.parquet`) : `chunk_id` stable (hash), `doc_id`, `doc_type`, `ingredients`, `mentioned_ingredients`, `section`, `chunk_index`, `title`, `text`, `source_name`, `url` (DailyMed, PubMed, DDInter), `date`, `version`, `license`, `article_type`, `is_retracted`, `language`, `retrieved_at`.
- **Versionnement** : `data/rag/raw`, `interim` et le manifeste par `dvc add` ; les chunks par l'étape `rag_corpus` de `dvc.yaml` ; tout est poussé sur le remote DVC (15 306 fichiers au total avec les images).

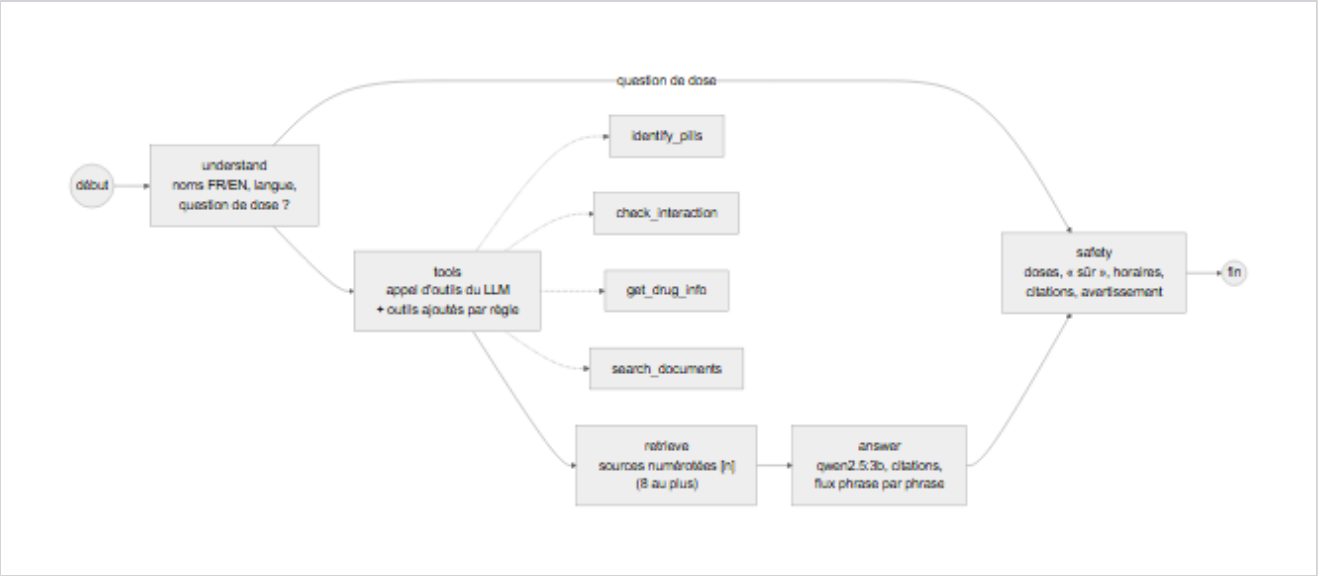
3. Découpage et exclusions de sécurité

- **Notices : par section**, 1 500 caractères au plus, coupées sur les fins de phrase avec une phrase de chevauchement. **Résumés : par paragraphe** (BACKGROUND, RESULTS…). **DDInter : une ligne par paire.** Chaque chunk a un titre de contexte (« Fluconazole label (Diflucan): Drug interactions ») indexé avec le texte. Longueur moyenne 687 caractères.
- **Exclusions** : les sections `dosage_and_administration`, `dosage_forms_and_strengths`, `overdosage`, `how_supplied`, emballage, pharmacocinétique et études cliniques sont **retirées avant l'écriture** du fichier brut, refusées par le schéma Pydantic et par le découpeur (tests dédiés). Limite : d'autres sections citent des quantités (1 010 chunks contiennent « mg ») ; c'est le nœud de sécurité de l'agent qui retire toute phrase de réponse avec une dose, et l'interface masque ces phrases dans les extraits affichés.

4. Récupération

- **Embeddings bge-m3** (multilingue, 1 024 dimensions) servis par Ollama (D59), 0,7 Go de VRAM, compatible avec le LLM sur le même GPU. Une phrase française et sa traduction anglaise : cosinus 0,87 ; une phrase sans rapport : 0,53.
- **Stockage** : table `rag_chunks` dans PostgreSQL + **pgvector** (`vector(1024)`), métadonnées en colonnes, listes de principes actifs en `text[]`. Indexation idempotente (`python -m app.rag.index`) : 8 661 chunks en **364 s** sur la RTX 2050 ; deuxième passage : 0 recalculé en 0,1 s.
- **Trois modes** : **BM25** (en mémoire, ≈ 6 ms), **dense** (cosinus exact en SQL, 130-190 ms, surtout l'embedding de la question), **hybride** RRF k = 60 (≈ 170 ms). Filtres : principe actif (sujet ou cité), type de document, section, articles rétractés exclus par défaut. Pas d'index HNSW : à cette taille, la recherche exacte suffit.
- **Choix mesuré** (section 7) : **dense + filtre de principe actif** par défaut (D65).

5. Agent LangGraph



Graphe de l'agent : la question de dose va directement au nœud de sécurité, sans appel au LLM.

Nœud	Rôle	LLM
`understand`	noms de médicaments en français ou en anglais (« warfarine » -> warfarin), comprimés confirmés, langue, question de dose ?	non
`tools`	le LLM choisit les appels (appel d'outils d'Ollama) ; le graphe ajoute ceux qui manquent : `check_interaction` pour deux médicaments ou plus, `search_documents` toujours (D64) ; chaque appel est marqué `llm` ou `rule`	oui
`retrieve`	sources numérotées [1], [2]… : DDInter d'abord, puis extraits de notice, puis résultats de recherche ; 8 au plus	non
`answer`	réponse à partir des sources seulement, citations [n], en flux phrase par phrase	oui
`safety`	règles de sécurité sur toute la réponse : réécriture ou refus	non

Outils (outils LangChain, mêmes fonctions que le serveur MCP) : `identify_pills` (la logique de `/api/scan`), `check_interaction` (celle de `/api/interactions`), `get_drug_info` (classes de comprimés et extraits de notice), `search_documents` (recherche avec filtres). Ajouter un outil = une méthode de `Toolbox` et une entrée de `TOOL_SPECS`.

Nœud de sécurité (règles en code, D63) :

1. **Pas de dose** : une question de dose est refusée **avant tout appel au LLM** ; une phrase avec une quantité de médicament (« 50 mg », « deux fois par jour ») ou un conseil d'ajustement de dose est retirée ; les valeurs biologiques (« eGFR 30 mL/min ») ne sont pas des doses.
2. **Jamais « sûr »** : une phrase « sûr / sans danger / safe » est retirée, et remplacée par « Aucune interaction connue dans cette base de données. » si rien n'est trouvé.
3. **Pas d'horaire inventé** : un conseil d'intervalle ou de repas n'est gardé que s'il cite une source.
4. **Citations** : `[n]` doit pointer vers une source ; une phrase sans citation est rattachée à la source qui contient au moins 60 % de ses mots, ou par le sens (bge-m3, D68) ; sans aucune source, pas de réponse.
5. **Avertissement** : chaque réponse se termine par « Information uniquement, consultez un pharmacien ou un médecin. »

En flux, une phrase interdite n'est jamais affichée. `POST /api/chat` (asynchrone, connexion requise) renvoie la réponse, les citations (titre, URL, section, extrait, `cited`), les appels d'outils, le résultat du contrôle de sécurité et les temps ; avec `stream: true`, des événements SSE `tool`, `token`, `final`.

6. Serveur MCP et LLM local

- **MCP** : `backend/app/mcp_server.py`, SDK Python officiel (`mcp` 2.3), les **mêmes outils** que l'agent (même code ; 4, plus `predict_toxicity` en bonus), consignes de sécurité dans les `instructions` du serveur ; transports stdio et streamable HTTP (limité à `127.0.0.1`). Test de fumée réel (`scripts/mcp_smoke.py`, ≈ 11 s, avant le bonus) : 4 outils listés, warfarine + fluconazole -> Major, « metformin lactic acidosis » -> notices de la metformine. 3 tests (liste et schémas, appels, refus d'une adresse non locale).
- **Choix du LLM** (D58), sur une RTX 2050 de 4 Go, même question courte en français :

Modèle	VRAM	Placement	Vitesse	Temps de réponse
qwen2.5:3b	2,2 Go	100 % GPU	47,4 jetons/s	**1,7 s**
llama3.2:3b	2,9 Go	80 % GPU	32,0 jetons/s	3,2 s
gemma3:4b	2,9 Go	55 % GPU	11,8 jetons/s	12,1 s
qwen3:4b	2,9 Go	82 % GPU	14,0 jetons/s	89,9 s

qwen2.5:3b est le seul entièrement sur le GPU, le plus rapide, avec un bon français et l'appel d'outils. Réglages trouvés par le benchmark (D68) : contexte 4 096 jetons (avec 8 192, le LLM et bge-m3 ne tenaient plus ensemble sur le GPU) et 450 jetons de réponse au plus (une réponse avait bouclé sur plus de 24 000 jetons).

7. Benchmark

7.1 Jeu de questions

88 questions (44 FR, 44 EN) sur les 82 principes actifs : 24 interactions, 12 contre-indications, 10 encadrés, 10 mécanismes, 10 effets indésirables, 8 mises en garde, 9 constats d'articles PubMed, 5 questions pièges (2 doses, 2 « est-ce sûr », 1 horaire). Construites par règles à partir du corpus (chunks attendus, référence extraite), puis **relues à la main** (D66) : grammaire corrigée, 2 questions remplacées, 14 références d'interaction et 9 références d'articles réécrites, aucune référence avec une dose.

7.2 Récupération (83 questions avec chunks attendus, top 10)

Mode	Filtre	Recall@1	Recall@3	Recall@5	Recall@10	MRR
BM25	aucun	0,554	0,711	0,735	0,783	0,637
dense (bge-m3)	aucun	0,783	0,867	0,904	0,976	0,841
hybride (RRF)	aucun	0,699	0,855	0,892	0,940	0,779
BM25	principe actif	0,566	0,747	0,783	0,819	0,660
dense	**principe actif**	**0,795**	**0,880**	**0,928**	**0,976**	**0,852**
hybride	principe actif	0,711	0,892	0,904	0,928	0,796

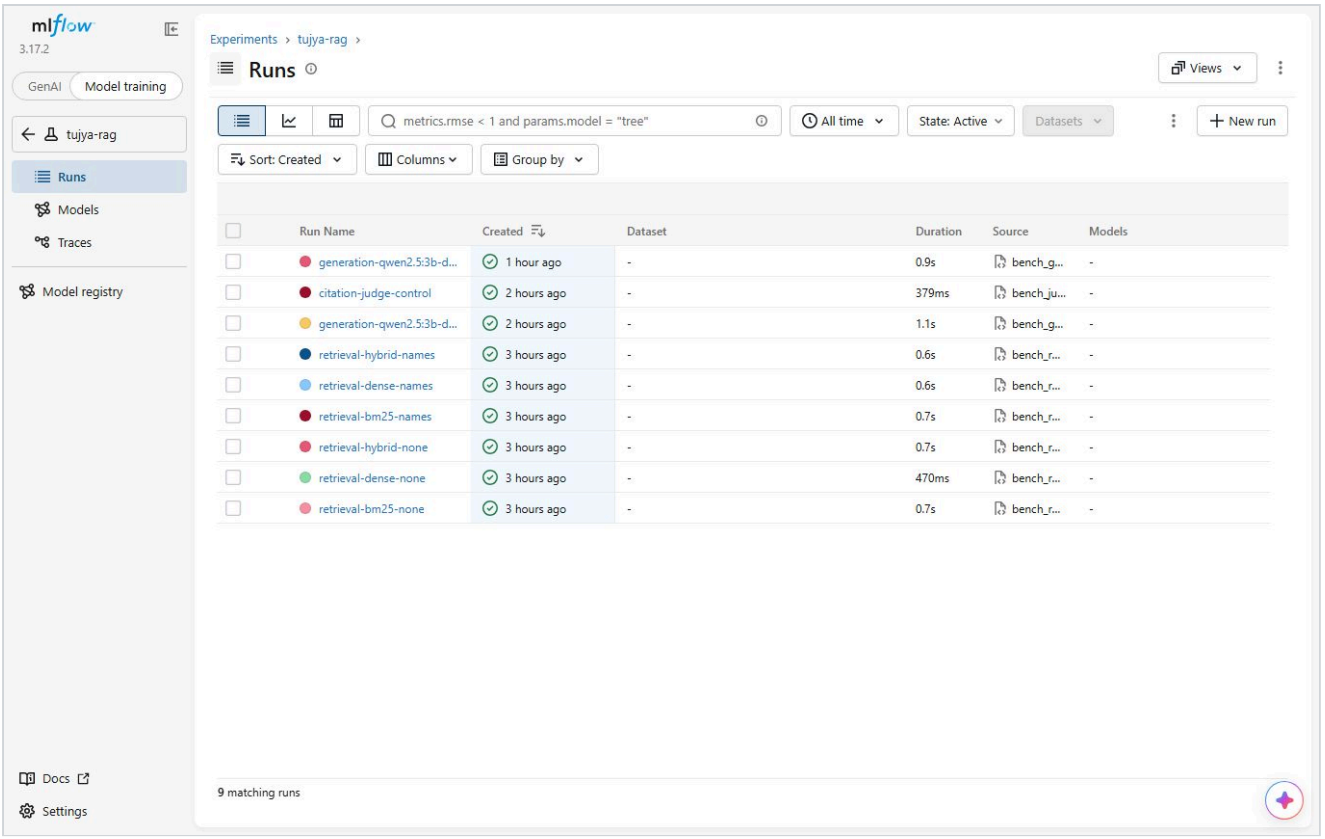
BM25 contre dense : le corpus est en anglais ; BM25 échoue sur les questions françaises (Recall@5 0,585 contre 0,976 en anglais) et tire l'hybride vers le bas. En anglais seul, l'hybride est légèrement meilleur (MRR 0,944 contre 0,937). Le dense filtré devient le réglage par défaut ; une traduction de la requête pour BM25 n'a pas été tentée, pour ne pas ajuster le système à son propre jeu de test.

7.3 Génération (agent réel sur les 88 questions ; juge gemma3:4b, D67)

Contrôle	Résultat
Avertissement en fin de réponse	100 %
Phrases avec une dose chiffrée	0
Conseils d'ajustement de dose sans chiffre (règle étendue après ce run)	4
Phrases disant « sûr » / « safe »	0
Questions de dose refusées (avant tout appel au LLM)	2 / 2
Phrases de réponse avec une citation [n]	69,8 %
Phrases citées soutenues par leur source (juge)	**94,0 %** (FR 90,0 %, EN 96,5 %)
Contrôle du juge : « oui » pour une source sans rapport	10,0 % (4 / 40)
Temps de réponse (modèles chargés)	moyenne 4,7 s, médiane 4,5 s

RAGAS 0.4.3 sur un sous-ensemble de 8 questions (une par type) : fidélité **0,979** (6/8 notées), précision du contexte **0,809** (8/8), pertinence de la réponse **non calculable** (sorties du juge illisibles). Le juge local de 4B est bien plus faible que ceux prévus par RAGAS : ces scores servent à comparer des runs de ce système.

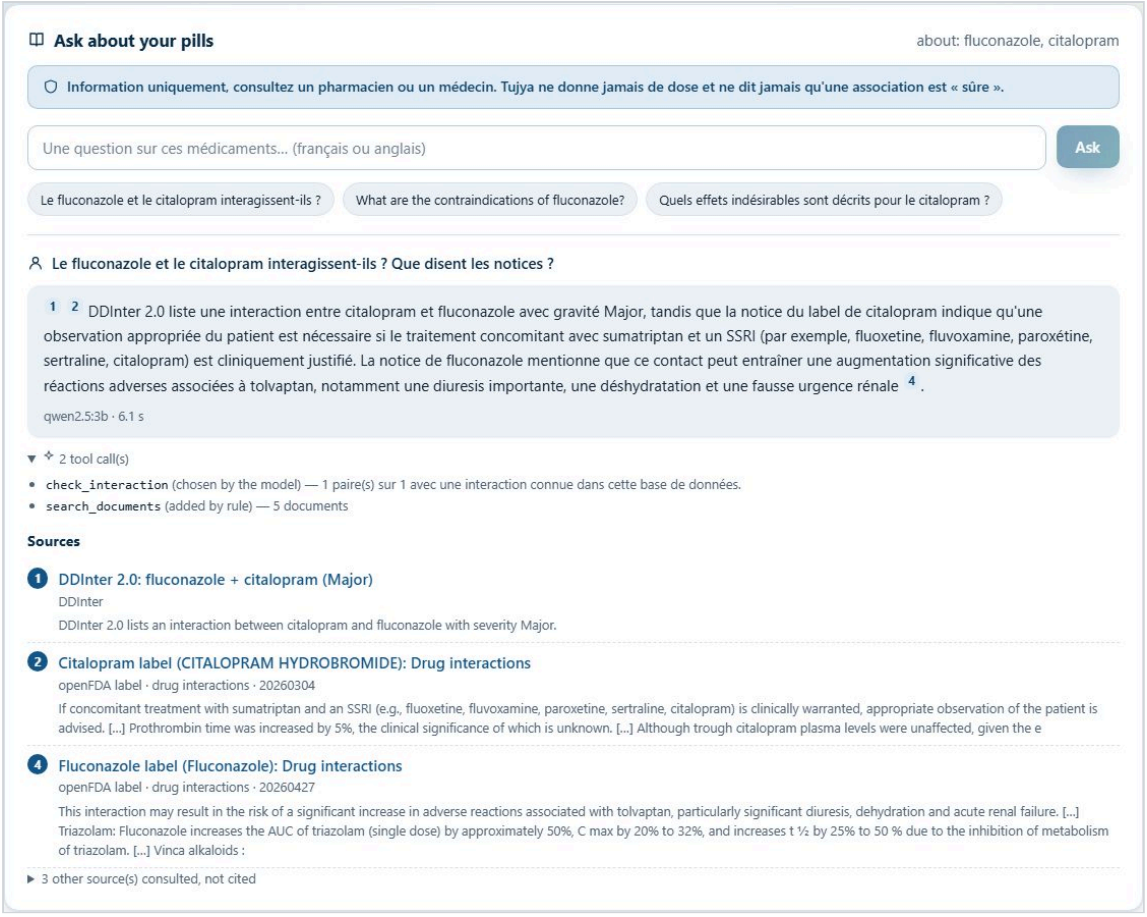
Tous les runs sont dans MLflow (expérience `tujya-rag` : 6 runs de récupération, 2 de génération, 1 de contrôle du juge).



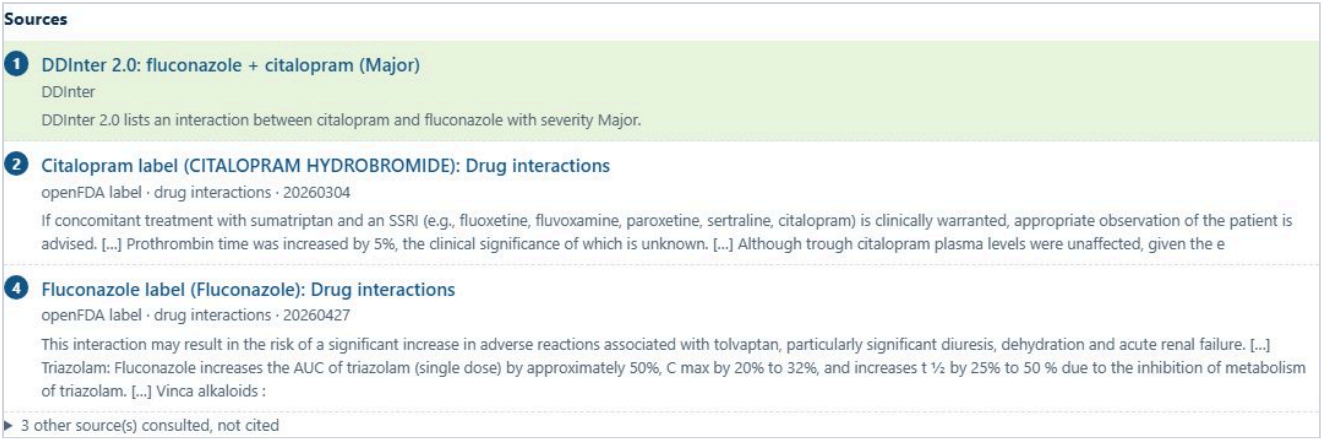
Expérience tujya-rag dans MLflow.

8. Interface de chat

Panneau « Ask about your pills » sous la page Scanner : suggestions à partir des comprimés confirmés, réponse en flux SSE phrase par phrase (déjà vérifiée), citations numérotées cliquables vers la liste des sources (titre, type, section, date, extrait sans dose), appels d'outils repliables, badge quand le contrôle de sécurité a modifié ou refusé la réponse, avertissement toujours visible. Sur les conteneurs : réponse en **5,6 s** une fois les modèles chargés (la toute première question après un démarrage a pris 83,9 s, d'où une étape de préchauffage dans le script de démo).



Réponse réelle avec citations, appels d'outils et sources.



Après un clic sur [1] : la source surlignée.



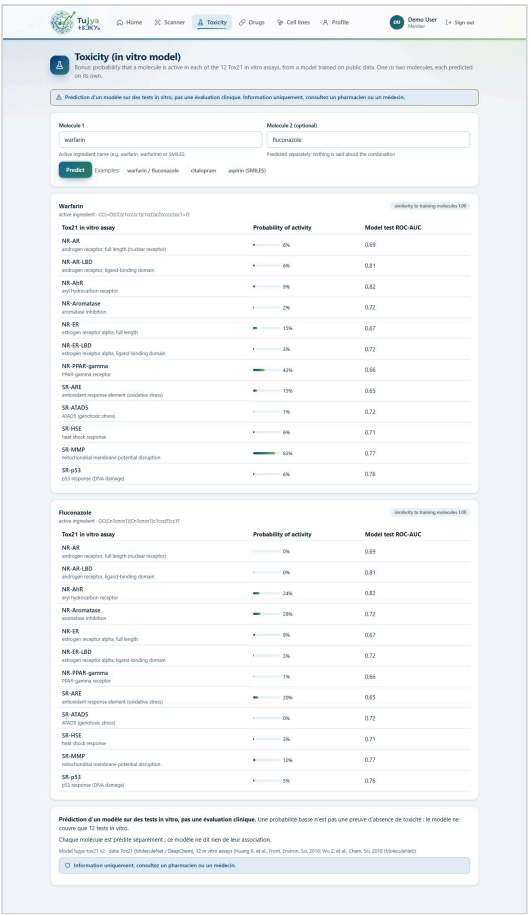
Question de dose refusée.

9. Bonus : outil de toxicité (Tox21)

Cinquième outil, `predict_toxicity` (agent, serveur MCP, `POST /api/toxicity`, page « Toxicity ») : pour une ou deux molécules (nom de principe actif ou SMILES), probabilité d'activité dans les 12 tests in vitro de

Tox21, toujours présentée comme une **« prédiction d'un modèle sur des tests in vitro, pas une évaluation clinique »**, chaque molécule séparément, jamais rien sur leur association (docs/TOXICITY.md).

- Données : Tox21, copie MoleculeNet (7 831 molécules) ; aucune licence explicite trouvée (données publiques d'agences fédérales américaines), citées, versionnées par DVC (D73).
- Modèle : empreintes Morgan RDKit (rayon 2, 2 048 bits), un LightGBM par test, **split par scaffold** (6 258 / 782 / 783) : ROC-AUC moyen **0,725** en test (de 0,647 pour SR-ARE à 0,822 pour NR-AhR), 0,766 en validation ; fort surapprentissage (ROC-AUC d'entraînement proche de 1). MLflow `tujya-tox`, modèle enregistré `tujya-tox21` v2.
- **Leçon de sécurité** (D74) : en essayant le vrai agent, qwen2.5:3b a mal lu les probabilités (warfarine « pas identifiée comme toxique » alors que SR-MMP = 0,83). Les phrases sur la prédiction sont donc écrites par le code à partir du résultat de l'outil, et une règle retire toute affirmation « non toxique ». Vérifié ensuite sur les conteneurs.



Page Toxicity : une carte par molécule, formulation et avertissement toujours visibles.

10. Limites et suite

- **Modèle de 3B** : réponses justes et citées pour les contre-indications, mécanismes, encadrés et sévérités DDInter, mais phrases hors sujet prises dans la même section de notice (fluconazole + citalopram : tolvaptan, triazolam), un détail inventé une fois, une liste de sources recopiée une fois ; 30 % des phrases sans citation. Un modèle de 7-8B ne tient pas dans 4 Go.
- **Benchmark** : questions sur modèle, construites et relues par la même personne ; un seul ensemble de chunks attendus (scores en borne basse) ; juge de 4B ; RAGAS sur 8 questions.
- **Sécurité par expressions régulières** (FR, EN) : une dose écrite autrement pourrait passer ; à l'inverse, des phrases sans danger sont parfois retirées.

- **BM25 en français** : pas de traduction de requête ; hybride non retenu.
- Suite : filtrer les phrases des sources qui ne parlent pas des médicaments de la question, un LLM plus grand sur un GPU plus gros, RAGAS sur tout le jeu avec un juge plus fort, un benchmark écrit par une autre personne, interface en français.

11. Références

- openFDA drug label API : https://open.fda.gov/apis/drug/label/.
- NCBI E-utilities (PubMed) : https://www.ncbi.nlm.nih.gov/books/NBK25501/.
- DDInter 2.0 : https://ddinter2.scbdd.com/ (CC BY-NC-SA 4.0).
- J. Chen et al., « BGE M3-Embedding », arXiv:2402.03216 (bge-m3).
- Qwen2.5 (Alibaba) ; Ollama https://ollama.com/.
- LangGraph / LangChain https://www.langchain.com/langgraph ; Model Context Protocol https://modelcontextprotocol.io/.
- pgvector https://github.com/pgvector/pgvector ; S. Robertson, H. Zaragoza, « The Probabilistic Relevance Framework: BM25 and Beyond », 2009 ; G. Cormack et al., « Reciprocal Rank Fusion », SIGIR 2009.
- R. Huang et al., « Tox21 Challenge to Build Predictive Models of Nuclear Receptor and Stress Response Pathways… », Front. Environ. Sci. 2016 ; Z. Wu et al., « MoleculeNet: a benchmark for molecular machine learning », Chem. Sci. 2018 ; RDKit, LightGBM.
- S. Es et al., « RAGAS: Automated Evaluation of Retrieval Augmented Generation », arXiv:2309.15217.
- Documents du dépôt : docs/RAG.md, docs/AGENT.md, docs/MCP.md, docs/BENCHMARK.md, docs/DECISIONS.md (D57 à D72), docs/DEMO.md.